

PHÂN TÍCH THĂM DÒ DỮ LIỆU




1



Mục tiêu

- Vận dụng thống kê mô tả
- Vận dụng độ tương quan
- Phân tích gom nhóm dữ liệu cơ bản
- Vận dụng phân tích phương sai (ANOVA)



2

2



Nội dung

1. Phân tích thăm dò dữ liệu
2. Thống kê mô tả
3. Gom nhóm dữ liệu
4. Phân tích ANOVA

3

3



Bộ dữ liệu

Minh họa học lý thuyết và thực hành:

https://raw.githubusercontent.com/datasethub/ds105/master/EDA_automobile.csv

	symboling	normalized-losses	make	aspiration	num-of-doors	body-style	drive-wheels	engine-location	wheel-base	length	width	height	curb-weight	engine-type	num-of-cylinders	engine-size
0	3	122	alfa-romero	std	two	convertible	rwd	front	88.6	0.811148	0.890278	48.8	2548	dohc	four	130
1	3	122	alfa-romero	std	two	convertible	rwd	front	88.6	0.811148	0.890278	48.8	2548	dohc	four	130
2	1	122	alfa-romero	std	two	hatchback	rwd	front	94.5	0.822681	0.909722	52.4	2823	ohcv	six	152
3	2	164	audi	std	four	sedan	fwd	front	99.8	0.848630	0.919444	54.3	2337	ohc	four	109
4	2	164	audi	std	four	sedan	4wd	front	99.4	0.848630	0.922222	54.3	2824	ohc	five	136
5	2	122	audi	std	two	sedan	fwd	front	99.8	0.851994	0.920833	53.1	2507	ohc	five	136
6	1	158	audi	std	four	sedan	fwd	front	105.8	0.925997	0.991667	55.7	2844	ohc	five	136
7	1	122	audi	std	four	wagon	fwd	front	105.8	0.925997	0.991667	55.7	2954	ohc	five	136
8	1	158	audi	turbo	four	sedan	fwd	front	105.8	0.925997	0.991667	55.9	3086	ohc	five	131
9	2	192	bmw	std	two	sedan	rwd	front	101.2	0.849592	0.900000	54.3	2395	ohc	four	108

4

4



1. Phân tích thăm dò dữ liệu

EDA?

- EDA là một cách tiếp cận để phân tích dữ liệu. (khi bắt đầu từ 1 nguồn mới)
- Các bước sơ bộ trong phân tích dữ liệu để:
 - Tóm tắt các **đặc tính chính** của dữ liệu
 - Hiểu rõ hơn về tập dữ liệu
 - Phát hiện **mối quan hệ** khác nhau giữa **các biến/thuộc tính/cột**
 - **Trích xuất/chọn ra các biến quan trọng**
- Câu hỏi giải quyết vấn đề đặt ra:
“Những đặc điểm nào có ảnh hưởng nhất đến giá xe?”

5

5



1. Phân tích thăm dò dữ liệu



6


6



2. Thống kê mô tả

Giới thiệu

- Mô tả các đặc tính cơ bản của dữ liệu.
- Đưa ra các tóm tắt ngắn về mẫu và thang đo của dữ liệu.
- Là một trong những hướng tiếp cận để thăm dò dữ liệu.



7

7



2. Thống kê mô tả

Câu hỏi?

- Đối với bộ dữ liệu đang phân tích:
- 1. Ngoài việc hiểu ý nghĩa mô tả các biến thì tìm hiểu những gì để **hiểu rõ hơn** bộ dữ liệu?
- 2. Khi biết được **đặc điểm dữ liệu** của một biến thì xử lý giá trị khuyết cho biến đó như thế nào?

8

8



2. Thống kê mô tả

Thăm dò các đặc tính sau:

- 2.1. Hướng trung tâm (Central tendency)
- 2.2. Độ phân tán (Dispersion)
- 2.3. Hình dáng của dữ liệu (Shape)
- 2.4. Tương quan (Correlation)

9

9



2. Thống kê mô tả

Thăm dò chi tiết các đặc tính sau:

2.1. Central tendency (Hướng trung tâm)

- Mean
- Median
- Mode

2.2. Dispersion (Độ phân tán)

- Range
- Quartile
- Interquartile Range (IQR)
- Variance
- Standard deviation (std)
- Coefficient of Variation (CV)

2.3. Shape (Hình dáng)

- Skewness
- Kurtosis

2.4. Correlation (Tương quan)

10


10



2.1. Central tendency (Hướng trung tâm)

Giới thiệu

- Là thước đo tóm tắt, khái quát mức độ tổng thể của **từng biến** trong bộ dữ liệu
- Gồm
 - Mean
 - Median
 - Mode
- Ý nghĩa: hiểu về trạng thái **trung tâm** của dữ liệu, nghĩa là cho biết giá trị trung bình hoặc trung vị nằm ở đâu trong phạm vi của dữ liệu.
- (Trung tâm của dữ liệu nằm ở đâu?)



2.1. Central tendency

Mean

- Trung bình/bình quân của một bộ dữ liệu.
- Trong thống kê mô tả thì mean là **trung bình cộng**.
- Không phụ thuộc thứ tự các phần tử trong bộ dữ liệu.
- Công thức:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Ý nghĩa của mean?

- Hướng trung tâm về mặt **giá trị**.



2.1. Central tendency

Median

- Các giá trị của biến được sắp xếp có thứ tự thì **giá trị ở giữa** gọi là median (**trung vị**).
- Hoặc, median là giá trị nằm ở giữa tập dữ liệu sau khi được sắp xếp.

Ý nghĩa của median là gì?

- Thể hiện đặc trưng cho điểm giữa của sự phân tán giá trị của dữ liệu, còn được gọi là thống kê cho xu hướng trung tâm, hay thống kê vị trí.
- 50% giá trị mẫu là nhỏ hơn trung vị.
- Trung tâm về mặt **vị trí**.

...

13

13




2.1. Central tendency

Mode

- Có thể gọi là yếu vị.
- Là giá trị **xuất hiện nhiều nhất** trong bộ dữ liệu.
- Tập dữ liệu có 1 mode, hoặc tập dữ liệu có đến 2 hoặc 3 mode, hoặc tập dữ liệu không có mode nào.

10, 20, 15, 20, 25, 30, 35, 20, 20, 30, 15



Ý nghĩa của mode?

- Trung tâm về mức độ **tập trung dữ liệu**.
- Mô tả xu hướng phổ biến của các giá trị trong dữ liệu

...

14

14



2.1. Central tendency

Phương pháp

Phương thức	Mô tả
<code>df.mean()</code>	Tính trung bình
<code>df.median()</code>	Tính trung vị
<code>df.mode()</code>	Tính yếu vị
<code>df.describe()</code>	Tính cả 3 trung bình, trung vị, yếu vị

...


15

15




2.1. Central tendency

Đồ thị thể hiện



$\text{Mean} = \text{Median} = \text{Mode}$	Đối xứng (symmetry)
$\text{Mode} < \text{Median} < \text{Mean}$	Lệch phải
$\text{Mean} < \text{Median} < \text{Mode}$	Lệch trái



...


16

16



2.1. Central tendency

Đồ thị thể hiện



Mean = Median = Mode	Đối xứng (symmetry)
Mode < Median < Mean	Lệch phải
Mean < Median < Mode	Lệch trái

Mean bị kéo về phía các giá trị lớn (các outlier lớn), nên **Mean > Median > Mode**.
Median nằm giữa mean và mode.
Đuôi phải dài (tail kéo về phía các giá trị lớn).
Mode là giá trị xuất hiện nhiều nhất, nằm về phía bên trái.

...

17

17



2.1. Central tendency

Bài tập

- Tính mean, median, mode cho biến “price” và “length”
- Giới thiệu chọn chủ đề báo cáo.
Vận dụng mean, median, mode vào điền khuyết.

...

18

18




2.2. Dispersion (Hướnđ phân tán)

Giới thiệu

- Thang đo độ phân tán
- Mô tả mức độ các giá trị dữ liệu trải rộng hoặc **phân tán**.

Ý nghĩa:

- Độ phân tán nhỏ: dữ liệu ổn định, các giá trị gần nhau.
- Độ phân tán lớn: dữ liệu biến động mạnh, khó dự đoán.



19

19



2.2. Dispersion (Hướnđ phân tán)

Tính toán các đại lượng sau

1. Range - Khoảng biến thiên
2. Quartile - Tứ phân vị
3. Interquartile Range (IQR) - Độ trải giữa (khoảng tứ phân vị)
4. Variance - Phương sai
5. Standard deviation (std) - Độ lệch chuẩn
6. Coefficient of Variation (CV) - Hệ số biến thiên

20

20



2.2. Dispersion

Range

- Khoảng biến thiên
- Cho bộ dữ liệu với các giá trị quan sát được sắp xếp theo thứ tự:

$$X_1, X_2, X_3, \dots, X_n$$

Trong đó:

- $\text{Min} = x_1$
- $\text{Max} = x_n$
- Công thức: **Range** = $\text{Max} - \text{Min} = x_n - x_1$

Ý nghĩa của Range trong thống kê là gì?

- Khoảng biến thiên sẽ bị ảnh hưởng bởi các giá trị ngoại lệ (Outliers)

...

21


21



2.2. Dispersion

Quartile

- Chia tập dữ liệu thành 4 phần có số lượng quan sát như nhau, mỗi phần có chứa khoảng 1/4, tức 25% giá trị quan sát.
- Quartile cung cấp thông tin về các giá trị quan sát được phân bố từ Min tới Max.



...

22

22



2.2. Dispersion

Quartile

- Phân vị mẫu thứ nhất Q_1 (lower quartile)
- Phân vị mẫu thứ hai Q_2 = Median, còn gọi là sample median.
- Phân vị mẫu thứ ba Q_3 (upper quartile)
- Tính tứ phân vị:


$$Q_1 = X_{(q_1)}$$

$$Q_3 = X_{(q_3)}$$

với

$$q_1 = \frac{n+1}{4}$$

$$q_3 = \frac{3(n+1)}{4}$$



23

23




2.2. Dispersion

Interquartile Range (IQR)

- Độ trải giữa (khoảng tứ phân vị)
- $IQR = Q_3 - Q_1$

Ý nghĩa của IQR?

- Thể hiện khoảng rộng hay “sự phân tán” của tập số.



24

24



2.2. Dispersion

Variance (Phương sai)

- Phương sai của một tập mẫu là trung bình của bình phương độ lệch của các quan sát so với trung bình của chúng.

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

- Phương sai mẫu thì $n - 1$ để bù độ lệch gây ra do cách dùng giá trị trung bình

Ý nghĩa của phương sai?

- Đo lường mức độ lan rộng (sự phân tán/phân bố) của dữ liệu xung quanh giá trị trung bình.



...

25

25



2.2. Dispersion



Thể hiện phương sai khác nhau (Hình bên trái có phương sai lớn hơn)

...

26

26



2.2. Dispersion

Standard deviation (std)

- Standard deviation (std): Độ lệch chuẩn
- Độ lệch chuẩn đo độ rộng của dữ liệu, được trải rộng xung quanh giá trị trung bình.
- Công thức:

$$\text{std} = \sqrt{s^2}$$

27

27



2.2. Dispersion

Coefficient of Variation (CV)

- Là hệ số biến thiên.
- CV thường dùng để đo mức độ phân tán của các biến xung quanh giá trị trung bình của nó.
- Công thức:

$$CV = \frac{\sigma}{\mu} \times 100\%$$

28

28



2.2. Dispersion

Áp dụng - describe()

- Phương thức `describe()` thực hiện tóm tắt các thông số thống kê của các biến trong bộ dữ liệu.

df.describe()

	symboling	normalized-losses	wheel-base	length	width	height	curb-weight	engine-size
count	201.000000	201.000000	201.000000	201.000000	201.000000	201.000000	201.000000	201.000000
mean	0.840796	122.000000	98.797015	0.837102	0.915126	53.766667	2555.666667	126.875622
std	1.254802	31.99625	6.066366	0.059213	0.029187	2.447822	517.296727	41.546834
min	-2.000000	65.000000	86.600000	0.678039	0.837500	47.800000	1488.000000	61.000000
25%	0.000000	101.000000	94.500000	0.801538	0.890278	52.000000	2169.000000	98.000000
50%	1.000000	122.000000	97.000000	0.832292	0.909722	54.100000	2414.000000	120.000000
75%	2.000000	137.000000	102.400000	0.881788	0.925000	55.500000	2926.000000	141.000000
max	3.000000	256.000000	120.900000	1.000000	1.000000	59.800000	4066.000000	326.000000

...


29

29



2.2. Dispersion

Box plot (Biểu đồ hộp)



...

30


30



2.2. Dispersion

Box plot – Áp dụng minh họa (Dùng seaborn)

```
sns.boxplot(x= "drive-wheels", y= "price", data=df)
```



Áp dụng vẽ boxplot bằng Series.plot()

...

31

31



Bài tập áp dụng

1. Vẽ boxplot biến price dùng 2 cách: Series.plot(...) và seaborn.boxplot(...)
2. Tìm các mẫu dữ liệu khi biến price rơi vào ngoại lệ?

...

32


32




2.3. Shape of Data (Hình dạng của dữ liệu)

- Hình dạng của dữ liệu được đo bằng

Skewness (Độ lệch)



Kurtosis (Độ nhọn)



33

33



2.3. Hình dạng của dữ liệu

Skewness

- Dùng giá trị **trung bình** làm cơ sở trung tâm để xác định sự chuyển dịch của dữ liệu.
- Công thức:

$$skewness = \frac{1}{N} \frac{\sum_{i=1}^N (x_i - \mu)^3}{\sigma^3} \quad skewness = \frac{n}{(n-1)(n-2)} \frac{\sum_{i=1}^n (X_i - \bar{X})^3}{s^3}$$


34

34



2.3. Hình dạng của dữ liệu

Skewness



35

35



2.3. Hình dạng của dữ liệu

Ý nghĩa hệ số Skewness trong phân tích dữ liệu

- Sử dụng hệ số skewness kết hợp với biểu đồ để đánh giá phân phối của bộ dữ liệu.
- Đánh giá **độ lệch nghiêng** so với giá trị trung bình theo xu thế tích cực hay tiêu cực.

36

36



2.3. Hình dạng của dữ liệu

Kurtosis

- Kurtosis dựa vào độ cao của điểm đỉnh (peakedness).
- Kurtosis càng cao thì càng có nhiều ngoại lệ và đuôi càng dài.
- Công thức:

$$kurtosis = \frac{1}{N} \frac{\sum_{j=1}^N (x_j - \mu)^4}{\sigma^4} \quad kurtosis = \frac{n(n+1)}{(n-1)(n-2)(n-3)} \frac{\sum_{j=1}^n (x_j - \bar{x})^4}{s^4}$$


37

37



2.3. Hình dạng của dữ liệu

Kurtosis



Platykurtic distribution
Low degree of peakedness
Kurtosis < 0

Normal distribution
Mesokurtic distribution
Kurtosis = 0

Leptokurtic distribution
High degree of peakedness
Kurtosis > 0

38

38



2.3. Hình dạng của dữ liệu

Ý nghĩa hệ số Kurtosis trong phân tích dữ liệu

- Hệ số kurtosis là một thước đo tốt để đánh giá có những vấn đề nào liên quan đến các **giá trị ngoại lệ** trong bộ dữ liệu.
- Khi giá trị **kurtosis lớn** cho thấy tập dữ liệu gặp vấn đề nghiêm trọng đối với các giá trị ngoại lệ

...

39

39



Bài tập

1

- Đánh giá biến price rơi vào ngoại lệ?

2

- Chọn từng biến (kiểu số) để thăm dò?
 - Lệch?
 - Cao?
 - Ngoại lệ
 -

...

41

41



2.4. Correlation (Độ tương quan)

Câu hỏi

1. Trong bộ dữ liệu, các biến (kiểu số) nào có khả năng ảnh hưởng đến giá xe?
 2. Các biến engine-size, highway-mpg, peak-rmp có ảnh hưởng đến giá xe hay không?
- Phương án: Tập trung vào các biến (dạng số) và price để tiến hành thăm dò.



2.4. Correlation (Độ tương quan)

Correlation là gì?

- Thể hiện mức độ **phụ thuộc lẫn nhau** của các **biến khác nhau**.
- Ảnh hưởng giữa hai chiều dữ liệu.
- Ví dụ về tương quan:
 - Ung thư gan có liên quan đến rượu, bia
 - Giá vàng có liên quan giá dầu
- Tương quan **KHÔNG** thể hiện mối quan hệ kéo theo.
- **KHÔNG** có tính “bắt cầu”

...


44

44



2.4. Correlation

- Để thể hiện mối quan hệ giữa 2 biến là “mạnh” hay “yếu”..., chúng ta sử dụng **correlation**



...

45

45




2.4. Correlation

Dùng trực quan

- Tương quan giữa hai biến **engine-size** và **price**

```
sns.regplot(x= "engine-size", y= "prices", data=df)  
plt.ylim(0,)
```



46

46




2.4. Correlation

Dùng trực quan

- Tương quan giữa hai biến **highway-mpg** và **price**

```
sns.regplot(x= "highway-mpg", y= "prices", data=df)  
plt.ylim(0,)
```



47

47




2.4. Correlation

Dùng trực quan

- Tương quan (yếu) giữa hai biến **peak-rmp** và **price**

```
sns.regplot(x= "peak-rmp", y= "prices", data=df)  
plt.ylim(0, )
```



48

48



2.4. Correlation

Hệ số tương quan

- Thể hiện mối quan hệ giữa 2 biến là “mạnh” hay “yếu”...

	Hệ số tương quan	
	Đồng thuận	Không đồng thuận
Mạnh	0.8 đến 1	-1 đến -0.8
Vừa	0.5 đến 0.8	-0.8 đến -0.5
Yếu	0.3 đến 0.5	-0.5 đến -0.3
Không	0 đến 0.3	-0.3 đến 0

49

49



2.4. Correlation - Statistics

Tương quan Pearson

Dùng để đánh giá mức độ tương quan tuyến tính

- Đánh giá tương quan giữa 2 biến.
 - **Hệ số** tương quan tuyến tính
 - **P-value**: thể hiện mức độ chắc chắn về mối tương quan đã tính toán
- **Hệ số tương quan**
 - Close to **+1**: Large positive relationship
 - Close to **-1**: Large negative relationship
 - Close to **0**: No relationship
- **P-value**
 - P-value < 0.001 **Strong**
 - P-value < 0.05 **Moderate** (Vừa phải)
 - P-value < 0.1 **Weak**
 - P-value > 0.1 **No**


50

50



2.4. Correlation - Statistics

Tương quan Pearson



51

51



2.4. Correlation - Statistics

Minh họa tương quan Pearson

- Xét mối quan hệ tương quan giữa 2 biến horsepower và price?

```
Pearson_coef, p_value = stats.pearsonr(['horsepower'], df['price'])
```

- Hệ số tương quan Pearson: **0.81**
- Giá trị P-value: **9.35e-48**


52

52



2.4. Correlation - Statistics

Bản đồ nhiệt tương quan (Correlation heatmap)




53

53



Heat map dạng ma trận - Matrix heat map

Kỹ thuật



```
df = pd.DataFrame(data={
    'a': [0.2, 0.4, 0.6, 0.8],
    'b': [0.5, 0.3, 0.7, 0.9],
    'c': [0.9, 0.1, 0.5, 0.2]
}, index=['A', 'B', 'C', 'E'])
```

```
plt.figure(figsize=(6, 4))
sns.heatmap(df, annot=True, fmt=".2f", cmap="coolwarm",
            xticklabels=df.columns, yticklabels=df.index,
            linewidths=0.5)
```

```
plt.title("Matrix Heatmap (Seaborn)")
plt.xlabel("Columns")
plt.ylabel("Rows")
plt.tight_layout()
plt.show()
```

...


54

54



Heat map dạng ma trận - Matrix heat map

Kỹ thuật



```
df = pd.DataFrame({
    'X': [10, 8, 20],
    'Y': [5, 25, 15],
    'Z': [30, 18, 22]
}, index=['A', 'B', 'C'])
```

```
plt.figure(figsize=(5, 4))
plt.imshow(df, cmap='Blues', interpolation='nearest')
```

```
plt.xticks(ticks=range(df.shape[1]), labels=df.columns)
plt.yticks(ticks=range(df.shape[0]), labels=df.index)
plt.grid(False)
```

```
plt.colorbar(label='Giá trị') # Thêm colorbar
```

```
for i in range(df.shape[0]): # Hiển thị giá trị trên từng ô
    for j in range(df.shape[1]):
        plt.text(j, i, df.iloc[i, j],
                ha='center', va='center', color='black')
```

```
plt.title("Matrix Heatmap từ DataFrame (matplotlib)")
plt.tight_layout()
plt.show()
```

...

55

55



3. Gom nhóm

Câu hỏi?

- Tìm xem trong bộ dữ liệu, xe loại kiểu dáng gì và loại động cơ nào có khả năng ảnh hưởng đến giá xe
- Phương án: Tập trung thăm dò các biến sau:
 - drive-wheels
 - body-style
 - price

...

56

56



3. Gom nhóm

Phương thức df.groupby()

- Để gom nhóm dữ liệu, dùng phương thức **groupby()**:
 - Áp dụng được cho các biến dạng phân loại
 - Gom nhóm dữ liệu thành các phân loại khác.
 - Áp dụng được cho đơn biến hoặc đa biến.
- Đánh giá xem liệu có mối ảnh hưởng nào về giá của các giá trị trong hai biến phân loại “drive-wheels” và “body-style”.

...

57

57



3. Gom nhóm

• Bước #1

```
df_test = df[['drive-wheels', 'body-style', 'price']]
df_test
```

• Bước #2

```
df_grp = df_test.groupby(['drive-wheels', 'body-style'], as_index = False).mean()
df_grp
```

	drive-wheels	body-style	price
0	rwd	convertible	13495.0
1	rwd	convertible	16500.0
2	rwd	hatchback	16500.0
3	fwd	sedan	13950.0
4	4wd	sedan	17450.0
5	fwd	sedan	15250.0
6	fwd	sedan	17710.0
7	fwd	wagon	18920.0
8	fwd	sedan	23875.0
10	rwd	sedan	16430.0

	drive-wheels	body-style	price
0	4wd	hatchback	7603.000000
1	4wd	sedan	12647.333333
2	4wd	wagon	9095.750000
3	fwd	convertible	11595.000000
4	fwd	hardtop	8249.000000
5	fwd	hatchback	8365.166667
6	fwd	sedan	9811.800000
7	fwd	wagon	10061.181818
8	rwd	convertible	23949.600000
9	rwd	hardtop	24202.714286
10	rwd	hatchback	14337.777778
11	rwd	sedan	21711.833333
12	rwd	wagon	16994.222222

58

58



3. Gom nhóm

Phương thức Pivot()

- Một biến được trình bày theo **cột**, các biến còn lại trình bày theo **dòng**

```
df_pivot = df_grp.pivot(index= 'drive-wheels', columns='body-style')
```

	price				
body-style	convertible	hardtop	hatchback	sedan	wagon
drive-wheels					
4wd	20239.229524	20239.229524	7603.000000	12647.333333	9095.750000
fwd	11595.000000	8249.000000	8396.387755	9811.800000	9997.333333
rwd	23949.600000	24202.714286	14337.777778	21711.833333	16994.222222

59

59




3. Gom nhóm

Dùng heatmap

```
plt.pcolor(df_pivot, cmap='RdBu')
plt.colorbar()
plt.show()
```

- Quy tắc màu của heatmap?



...

60

60



3. Gom nhóm

Phương thức value_counts()

- Phương thức value_counts() dùng để đếm các giá trị dạng phân loại.
- Ví dụ, đếm các giá trị trong biến “drive-wheels”

```
drive_wheels_counts=df["drive-wheels"].value_counts().to_frame()
```

```
drive_wheels_counts.rename(columns={'drive-wheels':'value_counts' inplace=True)
drive_wheels_counts.index.name= 'drive-wheels'
```

	value_counts
drive-wheels	
fwd	118
rwd	75
4wd	8

...

61

61



4. Phân tích ANOVA

Giới thiệu

- ANOVA: Analysis of Variance - Phân tích phương sai
- Phương pháp thống kê dùng để kiểm phân tích trung bình từ hai nhóm trở lên có khác nhau theo ý nghĩa thống kê hay không

Ví dụ

- Có sự khác biệt nào giữa các hãng xe

...

62

62



4. Phân tích ANOVA

Tại sao phân tích ANOVA (phân tích phương sai)?

- Xem xét khả năng ảnh hưởng giữa các nhóm khác nhau trong cùng một biến dạng phân loại.
- Phương pháp t-test dùng để kiểm định hai nhóm (biến binary).
- Tương tự, Point Biserial correlation
 - Ví dụ: so sánh xe chạy bằng xăng hay dầu, loại nào ảnh hưởng đến giá?
- Phân tích ANOVA áp dụng cho kiểm định cho nhiều nhóm.
 - Ví dụ: kiểm tra xem **honda**, **mec**, **toyota** và **bmw**, hãng nào ảnh hưởng đến giá xe hơn?

...

63

63



4. Phân tích ANOVA

Ví dụ

- Có 3 cửa hàng bán lẻ, doanh thu của từng sản phẩm trong cửa hàng như sau (đơn vị triệu):
 1. Cửa hàng 1 = [75, 89, 70, 90, 99, 67]
 2. Cửa hàng 2 = [54, 78, 87, 98, 76]
 3. Cửa hàng 3 = [98, 89, 91, 86, 57, 39, 89]
- Đánh giá xem có sự khác biệt đáng kể nào về doanh thu trung bình của từng cửa hàng.

64


64



4. Phân tích ANOVA

Ví dụ

- So sánh xe honda và bmw, hãng nào ảnh hưởng giá cao hơn?



65

65



4. Phân tích ANOVA

Phân tích ANOVA cần xác định hai giá trị sau?

- **F-test** được tính bằng:

Bình phương trung bình giữa các nhóm (*variation between groups*)

Bình phương trung bình trong mỗi nhóm (*variation within group*)

- **P-value**: (confidence degree/mức độ tự tin) kết quả thu được có ý nghĩa thống kê hay không.

66


66



4. Phân tích ANOVA

ANOVA – F-test

- F-test (nhỏ) thì khả năng ảnh hưởng (yếu) giữa các biến phân loại và biến mục tiêu



67


67



4. Phân tích ANOVA

ANOVA – F-test

- F-test (lớn) thì khả năng ảnh hưởng (mạnh) giữa các biến phân loại và biến mục tiêu



68

68



4. Phân tích ANOVA

Cài đặt

```
import scipy.stats as stats
```

```
fvalue, pvalue = stats.f_oneway(groupA,  
                                  groupB,  
                                  groupC, ...)
```

69

69



4. Phân tích ANOVA

Áp dụng

```
import scipy.stats as stats

# Dữ liệu mẫu cho ba lớp
ch01 = [75, 89, 70, 90, 99, 67]
ch02 = [54, 78, 87, 98, 76]
ch03 = [98, 89, 91, 86, 57, 39, 89]

# Thực hiện phân tích ANOVA
f1, p_value = stats.f_oneway(ch01, ch02, ch03)

# In kết quả
print("Giá trị thống kê F:", f1)
print("P-value:", p_value)

# Kiểm tra sự khác biệt đáng kể
alpha = 0.05
if p_value < alpha:
    print("Có sự khác biệt đáng kể giữa các cửa hàng.")
else:
    print("Không có sự khác biệt đáng kể giữa các cửa hàng.")
```

...

70

70




4. Phân tích ANOVA

Áp dụng vào bộ dữ liệu xe, kiểm tra xem biến “drive-wheels” hoặc “make” có ảnh hưởng đến giá hay không?

Hướng dẫn:

1. Vẽ Boxplot => nhìn hình => bình luận
2. Phân tích nhóm, tính f và p
3. Gom các giá trị của các nhóm không ảnh hưởng.



...

71

71



4. Phân tích ANOVA

Áp dụng vào bộ dữ liệu

• **Bước #1:** `grouped_anova = df_anova.groupby(['make'])`

• **Bước #2:**

➤ **Giữa honda và subaru**

```
anova_result = stats.f_oneway(grouped_anova.get_group('honda')['price'],  
                              grouped_anova.get_group('subaru')['price'])
```

```
F_onewayResult(statistic=0.19744030127462606, pvalue=0.6609478240622193)
```

➤ **Giữa honda và jaguar**

```
anova_result = stats.f_oneway(grouped_anova.get_group('honda')['price'],  
                              grouped_anova.get_group('jaguar')['price'])
```

```
F_onewayResult(statistic=400.925870564337, pvalue=1.0586193512077862e-11)
```

...

72

72



Kết luận

Công việc cần làm trong phân tích thăm dò dữ liệu

- Kích cỡ bộ dữ liệu (Size - Shape).
 - Ý nghĩa từng biến/cột.
 - Phân tích thăm dò => Thống kê mô tả => Thăm dò từng biến.
 - Đánh giá giá trị ngoại lệ.
 - Xét độ tương quan (thống kê).
 - Phân tích ANOVA
- => Trích xuất biến quan trọng ảnh hưởng đến mục tiêu.

...

73

73



Bài tập

- Sử dụng bộ dữ liệu giá xe
- Chọn biến quan trọng ảnh hưởng đến giá xe
- Hướng dẫn:
 - Các biến kiểu số => corr: ngoài -0.3 đến 0.3
 - Các biến kiểu phân loại => ANOVA => p-value < 0.05

...

74

74



76



Hỏi - Đáp



...

77